

HANDOVER · INTERNAL

AI 에이전트 및 프롬프트 명세서

문서번호 DUBBY-AIP-001

제품 버전 3.0.12

파이프라인 버전 3.0

작성일 2026-09-05

상태 **인수인계용 / 내부**

이 문서는 Dubby가 실제로 보내는 포괄 프롬프트 할당 규칙을 고정한다. 런타임 경계는 SAD-001 제품 기능은 FRS-001과 유사하지만, 포괄 프롬프트 할당은 Dubby AIP와 다르다.

저장소 코드 기준 (강제 프롬프트 없음)

1. 문서 개요

1.1 목적

이 문서는 Dubby 3.0.12 워커가 외부 모델에 보내는 **실제 프롬프트 전문**과 할당 계약을 인수 인계 기준으로 고정한다. 다음 엔지니어가 Gemini 전체 문서 번역 후 슬라이스 할당으로 되돌리지 않도록, 현재 코드의 per-idx 계약을 그대로 옮긴다. 프롬프트 본문은 코드와 같은 언어 (대부분 영어)를 유지한다.

1.2 범위

- 포함: Provider 기본값과 환경 변수 *이름*, transcribe/dub/편집기 재번역 호출 그래프, Gemini-OpenAI-xAI 프롬프트 전문, 번역 할당·재시도, STT 꼬리 재청취에 넣는 오디오, ElevenLabs API 파라미터, 재시도 정책, 3.0.12 버그 계약.
- 제외: Caddy-CORS-터널, 크레딧 UX, 테이블 DDL·마이그레이션. 비밀 값(API 키)은 적지 않는다.
- 사실의 기준: 저장소 현재 코드(제품 3.0.12, PIPELINE_VERSION = "3.0"). 코드에 없는 프롬프트는 만들지 않는다. LLM이 없는 단계는 "프롬프트 없음"으로 명시한다.

1.3 관련 문서

문서	역할
시스템 아키텍처 정의서 (DUBBY-SAD-001)	런타임·배포·네트워크·저장 경계. 누가 Gemini/OpenAI/ElevenLabs를 호출하는지만.
비즈니스 로직 및 기능 명세서 (DUBBY-FRS-001)	제품 기능, 크레딧 UX, 추출/더빙 화면
데이터베이스/파이프라인 설계서 (DUBBY-DPD-001)	스키마, 잡 단계, assign-by-idx 데이터 함의
본 문서 (DUBBY-AIP-001)	모델, 프롬프트 전문, 정렬·재시도 규칙
api/app/config.py, api/.env.example	환경 변수 이름(값 없음)

1.4 용어

용어	의미
per-idx 번역	idx N의 출력은 그 행의 source_text만 번역. 전체 대본은 문맥일 뿐.
assign-by-idx	모델 JSON의 translations[,idx]로만 매핑. 위치 배열로 빈 칸을 메우지 않음.
slice-from-full-doc	금지된 구계약. 문서 전체를 한 번에 번역한 뒤 문장을 idx에 잘라 넣음. 3.0.12에서 스크램블의 원인.

용어	의미
document_context	translate_batch(..., document_context=)로 넣는 전체 STT. Gemini는 full_transcript 필드로 보냄.
skip_proofread	Gemini STT 결과는 True. OpenAI Whisper proofread를 건너뛴.
API-only	저장된 자연어 프롬프트 없이 바이너리·폼 필드로만 호출.

1.5 명시적 비범위

- Caddy, DNS, 터널, CORS — SAD-001.
- 크레딧 UX, Stripe/RevenueCat 화면 — FRS-001.
- 테이블 DDL, jobs 큐, R2 키 — DPD-001.
- Demucs-ffmpeg-rubberband 커맨드라인 — DPD-001 9장. 본 문서 13장에서 “에이전트 아님”만 확인.

2. Provider 지도

설정은 `api/app/config.py`. `pydantic-settings`가 필드명을 대문자 환경 변수로 읽는다. 값은 적지 않는다.

2.1 기본값

역할	설정 필드	환경 변수	기본
STT	<code>stt_provider</code>	<code>STT_PROVIDER</code>	<code>gemini</code>
STT 모델	<code>gemini_model</code> / <code>whisper_model</code>	<code>GEMINI_MODEL</code> / <code>WHISPER_MODEL</code>	<code>gemini-3.7-flash</code> / <code>whisper-1</code>
번역	<code>translation_provider</code>	<code>TRANSLATION_PROVIDER</code>	<code>gemini</code>
번역 fallback 모델	<code>translation_model</code>	<code>TRANSLATION_MODEL</code>	<code>gpt-4o-mini</code>
xAI (선택)	<code>xai_api_key</code> , <code>xai_base_url</code>	<code>XAI_API_KEY</code> , <code>XAI_BASE_URL</code>	비움. 모델이 <code>grok-*</code> 일 때만
Grok reasoning	<code>translation_reasoning_effort</code>	<code>TRANSLATION_REASONING_EFFORT</code>	<code>low</code>
화자분리	<code>diarization_provider</code>	<code>DIARIZATION_PROVIDER</code>	<code>openai</code>
화자분리 모델	<code>diarization_model</code>	<code>DIARIZATION_MODEL</code>	<code>gpt-4o-transcribe-diarize</code>
TTS	<code>elevenlabs_tts_model</code>	<code>ELEVENLABS_TTS_MODEL</code>	<code>eleven_v3</code>
립싱크	<code>lipsync_provider</code>	<code>LIPSYNC_PROVIDER</code>	<code>disabled</code>

2.2 관련 환경 변수 이름 (값 없음)

이름	용도
<code>GEMINI_API_KEY</code> , <code>GEMINI_BASE_URL</code>	AI Studio REST. 기본 URL <code>https://generativelanguage.googleapis.com/v1beta</code>
<code>OPENAI_API_KEY</code> , <code>OPENAI_BASE_URL</code>	Whisper, GPT 번역/교정/정렬, 화자분리
<code>XAI_API_KEY</code> , <code>XAI_BASE_URL</code>	<code>TRANSLATION_MODEL</code> 이 <code>grok-*</code> 일 때만. 키는 <code>xai-</code> 로 시작해야 함 (sk- 거부)
<code>ELEVENLABS_API_KEY</code> , <code>ELEVENLABS_BASE_URL</code> , <code>ELEVENLABS_VOICE_ID</code>	TTS-IVC. <code>VOICE_ID</code> 가 있으면 클론 생략
<code>VOICE_CLONE_SAMPLE_SECONDS</code> , <code>TTS_CONCURRENCY</code>	기본 60초, 4

이름	용도
TRANSLATION_BATCH_SIZE	기본 12. OpenAI/xAI 청크 크기. Gemini 1차는 전 항목 1요청
TRANSLATION_TIMING_TOLERANCE, TRANSLATION_TIMING_REWRITE	기본 0.22, true
PIPELINE_STEP_RETRIES, PIPELINE_RETRY_BACKOFF_SECONDS	기본 2, 2.0 → 최대 3회, 백오프 2s-4s
PYANNOTE_AUTH_TOKEN, PYANNOTE_MODEL	diarization_provider=pyannote일 때만
SYNC_API_KEY, SYNC_BASE_URL, SYNC_MODEL	립싱크. 기본 disabled라 호출되지 않음

프로덕션 부팅

STT 또는 번역이 gemini이면 GEMINI_API_KEY 필수. Grok이면 XAI_API_KEY 필수. 비밀 값은 이 문서와 커밋에 넣지 않는다.

3. 호출 그래프

오케스트레이션은 `api/app/worker/pipeline.py`. 공급자 분기는 `engine.py`의 `RealEngine`.

3.1 transcribe 잡

```
run_transcribe
  engine.extract_asr_audio          → ffmpeg (프롬프트 없음)
  engine.transcribe(asr_audio.mp3)
    STT_PROVIDER=gemini             → GeminiClient.transcribe   $4
    STT_PROVIDER=openai             → OpenAIClient.transcribe   $7.1 (prompt=None)
    _fill_uncovered_asr_tail?       → 같은 engine.transcribe(asr_tail.mp3) $10
    diarization_enabled?
      DIARIZATION_PROVIDER=openai    → OpenAI /audio/transcriptions $8 (프롬프트 없음)
      pyannote / mock / disabled     → 로컬 모델 또는 생략
    skip_proofread? (Gemini True)
      else                           → engine.correct_transcript → OpenAI GPT $9.1
  engine.translate_batch(items, document_context=full_transcript)
    TRANSLATION_PROVIDER=gemini      → GeminiClient.translate_batch $5
    openai / xai                     → OpenAIClient.translate_batch $7.2
```

3.2 dub 잡

```
run_dub
  Demucs split_stems                → 프롬프트 없음
  engine.prepare_voice              → ElevenLabs IVC API   $11
  engine.tts (병렬, tts_concurrency)
    ElevenLabs /v1/text-to-speech    $11 (프롬프트 없음, v3는 감정 태그 접두)
  TRANSLATION_TIMING_REWRITE?
    engine.adjust_translation         → OpenAI/Grok chat   $9.4
    다시 engine.tts
  선택 speech_to_speech              → ElevenLabs STS API
  ffmpeg / rubberband / mux / R2    → 프롬프트 없음
```

3.3 편집기 재번역 (API)

`api/app/routers/segments.py`는 `OpenAIClient`를 직접 만든다. `TRANSLATION_PROVIDER=gemini`여도 이 경로는 Gemini를 쓰지 않는다.

1. `correct_transcript` — OpenAI GPT, 실패하면 원문 유지.
2. `translate_batch` — OpenAI/Grok (`TRANSLATION_MODEL`). `document_context`는 `[idx]` text 줄 목록.

3.4 살아있는 메서드 vs 레거시

메서드	워커 transcribe/dub	비고
Gemini/OpenAI transcribe, translate_batch	사용	현재 계약
correct_transcript	Whisper 경로만	Gemini는 skip_proofread

메서드	워커 transcribe/dub	비고
adjust_translation	dub, rewrite 플래그 켜짐	compress만 호출
translate_document	미호출	프롬프트는 남아 있음. Gemini에 연결 금지
align_translation_to_segments	미호출	구 slice 정렬. 파이프라인에 되돌리지 말 것
whisper_vocab_prompt	미호출	locale_rules에만 존재. Whisper는 prompt=None

4. Gemini STT

파일: api/app/worker/gemini_client.py GeminiClient.transcribe. 엔드포인트

{GEMINI_BASE_URL}/models/{GEMINI_MODEL}:generateContent. 역할은 user 하나. 오디오 part + 텍스트 part. system_instruction 없음.

4.1 생성 설정

```
temperature: 0.1
responseMimeType: application/json
responseSchema: _TRANSCRIPT_SCHEMA
thinkingConfig.thinkingLevel: LOW
```

audioTimestamp는 보내지 않는다. Vertex 전용 필드이며 AI Studio 키에서 HTTP 400이 난다. 400이 필드 미인식이면 strip_unknown_generation_field가 thinkingConfig 등을 빼고 최대 3회 재전송한다(오케스트레이터 재시도와 별개).

4.2 응답 스키마

```
{
  "type": "object",
  "properties": {
    "full_transcript": {"type": "string"},
    "segments": {
      "type": "array",
      "items": {
        "type": "object",
        "properties": {
          "start_sec": {"type": "number"},
          "end_sec": {"type": "number"},
          "speaker": {"type": "string"},
          "text": {"type": "string"}
        },
        "required": ["start_sec", "end_sec", "speaker", "text"]
      },
      "required": ["start_sec", "end_sec", "speaker", "text"]
    }
  },
  "required": ["full_transcript", "segments"]
}
```

4.3 화자 규칙 조각

diarize=True (프로젝트가 화자분리 커짐):

Assign a stable speaker label (A, B, C, ...) so the same person keeps the same letter across the whole clip. Dialogue, couples, and interviews: every time a different person starts talking, start a NEW segment. Never put two people in one segment. Typical dialogue turns are 0.8-6 seconds.

diarize=False:

This is treated as a single narrator: set speaker to A on every segment.

4.4 사용자 프롬프트 전문

{lang} = LANGUAGE_NAMES.get(language, language). {speaker_rule} = 위 4.3.

You are a professional transcriber for video dubbing.
Listen to the ENTIRE audio. The spoken language is {lang}.
Transcribe ALL speech verbatim with correct spelling and diacritics. Keep greetings, closings, and speech under background music. Do not invent words. Do not omit the second half of the clip.
{speaker_rule}
Return JSON with:
- full_transcript: the complete source transcript as one coherent document (no timestamps).
- segments: utterance captions covering every spoken word, typically 2-12 seconds, split on sentence or speaker change.
start_sec / end_sec are seconds from the start of this audio file (00:03.920 → 3.92). Include millisecond decimals. Anchor every segment to audible speech; do not invent equal-length slices.
text is exactly what was spoken in that range.
The concatenation of segment texts must cover the same words as full_transcript. Sort segments by start_sec. start_sec < end_sec.

4.5 오디오 입력

- 15 MiB 이하: inline base64 (inline_data).
- 초과: Gemini Files API 업로드 후 file_data. ACTIVE까지 대기, 요청 후 delete.
- MIME: mp3/wav/flac/m4a/ogg/webm. 파이프라인 ASR은 mp3.

파서 normalize_transcript_segments는 speaker 문자열을 등장 순으로 speaker_1, speaker_2...로 바꾼다. 겹침은 중간점으로 자른다. skip_proofread=True, provider="gemini".

5. Gemini 번역 (3.0.12 현행 계약)

파일: GeminiClient.translate_batch. 위커는 pipeline.py에서 세그먼트마다 (idx, source_text, slot_seconds)를 넣고, document_context는 STT full_transcript(없으면 [idx] text 목록)이다.

되돌리지 말 것

현행 계약은 "각 idx는 그 행의 source_text만 번역. full_transcript는 이름·대명사·이야기 연속성용 문맥."이다. 전체 문서를 한 덩어리로 번역한 뒤 문장을 idx에 나눠 넣는 방식은 3.0.12에서 스크램블을 냈다. full_translation 스키마 필드가 있어도 서버는 그 문자열을 슬라이스하지 않는다. 매핑은 translations[].idx만 사용한다.

5.1 응답 스키마

```
{
  "type": "object",
  "properties": {
    "full_translation": {"type": "string"},
    "translations": {
      "type": "array",
      "items": {
        "type": "object",
        "properties": {
          "idx": {"type": "integer"},
          "text": {"type": "string"}
        },
        "required": ["idx", "text"]
      }
    }
  },
  "required": ["full_translation", "translations"]
}
```

파싱은 openai_client.parse_translation_content. 기대 idx가 빠지면 TRANSLATION_FAILED(retryable). 위치 보정 없음.

5.2 사용자 JSON

```
{
  "full_transcript": "{document_context 또는 [idx] source 목록}",
  "segments": [
    {
      "idx": 0,
      "source_text": "...",
      "target_seconds": 3.40,
      "max_chars": 31
    }
  ]
}
```

max_chars = spoken_char_budget(target_lang, duration). 초당 글자: ko 9, zh 6, ja 7.5, vi 12, en/es/pt 14, fr/de/id 13, th 10, 그 외 12. 하한 8.

Gemini 1차는 translation_batch_size로 쪼개지 않고 전 항목을 한 요청에 넣는다.
source_lang == target_lang이면 모델 호출 없이 원문을 반환한다.

5.3 1차 프롬프트 전문

{src}/{tgt} = 언어 표시명. {extra} = translation_pair_rules (§16). 빈 문자열일 수 있다. 실제 전송은 {prompt}\n\n{user_json}.

```
You are a professional dubbing translator.
Translate EACH numbered segment from {src} into spoken {tgt}.
full_transcript is context only: names, pronouns, and story continuity.
The text for idx N must translate ONLY that row's source_text.
- never put the document opening or a later scene onto the wrong idx
- never merge, split, drop, or reorder idxs
- a short source line must stay a short translation
- do not leave source-language wording in the target line
- fit target_seconds / max_chars by tightening wording, not by deleting meaning
- spell numbers and abbreviations as they should be spoken
{extra}
Return JSON with full_translation plus translations[{idx,text}].
```

5.4 오할당 행 재번역 프롬프트

1차 후 idxs_needing_retranslate(§6)가 고른 idx만 다시 호출. 이 요청에는 full_transcript를 넣지 않는다(다른 장면 문장을 다시 끌어오지 않게).

```
Translate EACH of these {src} captions into spoken {tgt}.
Translate only that caption's source_text. Do not use lines from other scenes. Keep short captions short.
{extra}
Return JSON with full_translation plus translations[{idx,text}].

{"segments":[{"idx":N,"source_text":"...", "target_seconds":3.4}, ...]}
```

재시도 결과를 1차 dict에 update한 뒤 apply_translation_postprocess(vi→ko 지명·통화 교정)를 적용한다.

6. 번역 할당 규칙

파일: `api/app/worker/translation_align.py`. 휴리스틱일 뿐 두 번째 LLM이 아니다.

6.1 idxs_needing_retranslate

아래 중 하나면 그 idx를 재번역 목록에 넣는다. `source_lang` 인자는 사용하지 않는다(`del source_lang`).

함수	참이 되는 조건
<code>target_missing_expected_script</code>	빈 문자열. ko: 한글 2자 미만. zh/ja: 지배 스크립트가 cjk가 아님
<code>translation_too_short_for_source</code>	원문 ≥ 48 자 인데 번역 $< \max(8, \text{len}(\text{source})//6)$ — 긴 캡션이 스텝으로 붕괴
<code>translation_expanded_from_short_source</code>	원문 ≤ 24 자, 번역 ≥ 36 자, 번역 $> \text{원문} \times 2$ — 짧은 줄에 다른 장면 장면
<code>translation_too_long_for_slot</code>	$\text{len}(\text{target}) > \max(\text{budget} \times 2.2, 28)$ — 짧은 슬롯에 문서 덤프

6.2 배치 크기와 타이밍 플래그

설정	기본	동작
<code>translation_batch_size</code>	12	OpenAI/xAI chunked. Gemini 1차에는 미적용
<code>translation_timing_tolerance</code>	0.22	TTS 길이 / 슬롯 $\leq 1+0.22$ 이면 rewrite 생략
<code>translation_timing_rewrite</code>	true	초과 시 <code>adjust_translation(..., "compress")</code>

타이밍 rewrite가 만든 문장은 `segments.target_text`를 덮지 않는다(편집기 번역 유지). 서버는 `_rewrite_diverges`로 새 토큰이 많거나 거의 비면 버린다.

7. OpenAI Whisper / GPT / xAI Grok

7.1 Whisper STT — 프롬프트 없음

OpenAIClient.transcribe는 주석대로 prompt=None을 고정한다. Ver 1.0에서 whisper-1이 프롬프트를 따라 읽고 실제 발화를 건너뛰는 문제가 있었다.

```
POST {OPENAI_BASE_URL}/audio/transcriptions
model: {WHISPER_MODEL}          # whisper-1
response_format: verbose_json
timestamp_granularities[]: word
timestamp_granularities[]: segment
temperature: 0
language: {source_lang}         # 있으면
# prompt: 보내지 않음
file: asr_audio.mp3
```

locale_rules.whisper_vocab_prompt(베트남어 어휘 힌트)는 테스트만 호출한다. 워커에 연결하지 말 것 — echo 재발 위험.

7.2 GPT / Grok 배치 번역

build_translation_messages. temperature 0.1. OpenAI는 strict json_schema segment_translations(translations 배열만, full_translation 없음). Grok은 같은 메시지에 reasoning_effort를 붙일 수 있다.

시스템 프롬프트 전문:

```
You translate dubbing subtitles. Translate each numbered segment from {src} to {tgt}. Rules: keep the meaning and tone; keep the translation concise enough to be spoken in the supplied duration; write natural native spoken language for voice-over; retain all required diacritics; spell numbers and abbreviations as they should be spoken; never merge, split, drop, or reorder segments; return one translation per idx. Use the full transcript context so pronouns, names, tense, and register stay consistent across segments – but still translate each idx independently without borrowing words from neighbors.
```

페어 규칙이 있으면 시스템 프롬프트 뒤에 \n\n{extra}.

사용자 JSON:

```
{
  "segments": [{"idx": 0, "text": "...", "target_seconds": 3.4}],
  "full_transcript": "..." // document_context가 있을 때만
}
```

OpenAI 경로는 Gemini식 idxs_needing_retranslate 재시도를 하지 않는다. postprocess만 적용한다.

8. 화자분리

기본 provider는 openai. 저장된 자연어 프롬프트 없음.

8.1 OpenAI (기본)

```
POST {OPENAI_BASE_URL}/audio/transcriptions
model: gpt-4o-transcribe-diarize
response_format: diarized_json
chunking_strategy: auto
language: {source_lang 2글자} // 있으면
file: asr_audio.mp3 // 전체 클립. 꼬리 재청취 파일이 아님
```

세그먼트 start/end/speaker/text를 SpeakerTurn으로 바꾼 뒤 normalize_speaker_ids → speaker_1...N (첫 등장 순 = Voice Box 슬롯).

8.2 pyannote / mock / disabled

- pyannote: pyannote/speaker-diarization-3.1 로컬 추론. 프롬프트 없음.
- mock: 고정 턴 3개. 테스트 전용.
- disabled: provider None. Gemini 라벨만 사용하거나 speaker_0.

8.3 STT 이후 후처리 (모델 호출 아님)

Gemini가 A/B를 붙여 긴 캡션으로 합치면 split_timed_texts_on_turns가 OpenAI/pyannote 턴으로 글을 자른다. collapse_minor_speakers는 3초 미만·8% 미만 라벨을 이웃 주요 화자로 접는다(가짜 3번째 보이스 슬롯 방지).

9. 교정·레거시 정렬·타이밍 rewrite

9.1 ASR proofread (OpenAI, Whisper 경로)

Gemini STT는 skip_proofread=True라 워커가 호출하지 않는다. Whisper 추출과 편집기 재번역만 사용.

시스템 프롬프트 전문:

```
You proofread {lang} ASR (speech-to-text) subtitles for dubbing. Fix clear recognition errors using FULL narrative context across neighboring idxs: wrong near-homophones, truncated words, nonsense tokens. Remove duplicated phrases repeated across neighboring idxs by shortening the later line – never blank an idx and never drop a subtitle. Do not rewrite style or add new meaning. Keep each idx as its own subtitle line. Return JSON {"translations": [{"idx":0,"text":"..."}]} – use the same idxs; field name is translations but values are corrected source lines.
```

베트남어 추가(asr_proofread_rules("vi")):

```
Vietnamese ASR pitfalls: keep diacritics; do not swap Đà Lạt with Đà Nẵng; prefer real-estate terms thổ cư, mặt tiền, thung lũng, sân mây, triệu when the audio supports them; remove spurious inserted words like hết when neighbors do not support them.
```

한국어 추가:

```
Korean example: if someone survives because caretakers fed them, prefer 살아지더라 over 사라지더라 when Whisper misheard survival as disappearance – choose the reading that makes sense with the surrounding story.
```

사용자 JSON: full_transcript는 전 항목 [idx] text, segments는 현재 청크. temperature 0. 배치는 translation_batch_size.

9.2 translate_document — 레거시, 워커 미호출

OpenAIClient.translate_document. 엔진 래퍼는 있으나 pipeline.py는 호출하지 않는다. Gemini 경로에 연결하면 구 버그(전체 문서 번역 후 슬라이스)가 재현된다.

```
Translate this complete {src} transcript into natural spoken {tgt} for voice-over dubbing. Preserve narrative flow, character names, tone, and pronouns consistently. Do not add narrator notes or timestamps. Return JSON {"translation":"..."}.
```

사용자: 교정된 전체 원문 문자열. schema: {translation: string}.

9.3 align_translation_to_segments — 레거시, 워커 미호출

전체 번역문을 idx에 나누는 구계약. 현재 워커는 쓰지 않는다. 다시 켜지 말 것.

```
You align a complete {tgt} dubbing translation onto numbered {src} source segments. CRITICAL RULES: (1) idx N may express ONLY the meaning of source N – never attach leftover clauses from a previous source onto a short following line; (2) if source N contains two clauses, both of their
```

```
meanings stay on idx N; (3) never continue a previous sentence into the next idx; never borrow words from neighbors; (4) a short source (e.g. one clause) must get a short matching translation – do not pad it with previous leftover dialogue; (5) cover the whole document without dropping content by placing each clause on the idx that owns that meaning. Return JSON {"translations": [{"idx":0,"text":"..."}]}.
```

사용자: full_translation + segments[{idx, source_text}]. 체크 크기 translation_batch_size.

9.4 adjust_translation (dub 타이밍 compress)

시스템 프롬프트 전문. direction은 워커가 "compress"만 넘긴다. 스키마 없음. 모델이 한 줄만 반환.

```
{Compress} this {tgt} dubbing line to speak naturally in about {target_seconds:.2f} seconds. CRITICAL: keep the SAME meaning and the SAME content words. Do not add new clauses, names, or ideas that are not already in the line. Do not finish a neighboring sentence. Return only the rewritten line.
```

사용자: 현재 더빙 한 줄. temperature 0.1. 공급자는 TRANSLATION_MODEL(gpt-4o-mini 또는 grok-*). Gemini가 아니다.

10. STT 꼬리 재청취

`_fill_uncovered_asr_tail`. 첫 STT가 클립 끝 전에 멈추면 후반 타임스탬프가 비고, 번역이 있어도 더빙 때 원음이 남는다.

10.1 발화 조건

- $\text{duration_ms} < 20_000$ 또는 $\text{covered_end} \geq \text{duration_ms} \times 0.85 \rightarrow$ 생략.
- $\text{tail_start} = \max(0, \text{covered_end} - 800)$. 남은 길이 $< 4_000\text{ms} \rightarrow$ 생략.

10.2 모델에 보내는 것

새 프롬프트를 만들지 않는다. ffmpeg로 `asr_audio.mp3`를 `[tail_start, duration_ms]`로 잘라 `scratch/asr_tail.mp3`를 만들고, 같은 `engine.transcribe`를 호출한다.

인자	값
오디오	잘린 꼬리 MP3만. 전체 클립이 아님
language	프로젝트 <code>source_lang</code>
duration_seconds	$(\text{duration_ms} - \text{tail_start}) / 1000$
diarize	프로젝트 <code>diarization_enabled</code> 와 동일
프롬프트	\$4 Gemini 또는 \$7.1 Whisper(prompt=None)

모델이 돌려준 start/end는 **꼬리 파일 기준 초**이다. 서버가 `+tail_start` 한 뒤 `covered_end`와 겹치는 초반을 버린다. 실패는 잡을 것은 실패시키지 않고 `asr_tail_failed` 경고만 남긴다.

11. TTS — ElevenLabs (프롬프트 없음)

자연어 시스템/유저 프롬프트가 없다. REST JSON이다.

11.1 Instant Voice Clone

- 샘플: vocals 스템에서 VOICE_CLONE_SAMPLE_SECONDS(기본 60) + 발화 ranges.
- POST /v1/voices/add, name/description만. 월간 한도 시 기존 보이스 fallback.
- ELEVENLABS_VOICE_ID가 있으면 클론을 건너뛴다.

11.2 합성

POST /v1/text-to-speech/{voice_id}?output_format=mp3_44100_128. 동시성 TTS_CONCURRENCY 기본 4. 자체 재시도 pipeline_step_retries+1.

vi/ur/th는 multilingual_v1/v2를 쓰면 강제 eleven_v3.

v3 바디:

```
{
  "text": "{optional emotion tag}{line}",
  "model_id": "eleven_v3",
  "voice_settings": {
    "stability": {v3 map},
    "similarity_boost": {emotion map, default 0.75}
  },
  "language_code": "{target_lang}" // 있으면
}
```

v3 stability: sad/whisper=1.0, calm/cheerful=0.5, angry/excited/energetic=0.0. v3는 speed를 보내지 않는다(0.7–1.2 클램프는 비-v3 voice_settings.speed).

v3 텍스트 접두(이미 [로 시작하면 생략):

emotion_tone	접두
whisper	[whispers]
excited, energetic	[excited]
angry	[angry]
sad	[sad]
cheerful	[happily]
calm 및 그 외	(없음)

비-v3는 EMOTION_VOICE_SETTINGS의 stability/similarity_boost/style + use_speaker_boost: true + speed + apply_text_normalization: on.

11.3 Voice Changer (선택)

VOICE_CHANGER_AFTER_TTS 기본 false. POST /v1/speech-to-speech/{voice_id}, model eleven_multilingual_sts_v2, remove_background_noise=true. 프롬프트 없음.

12. 감정·스타일 — LLM 아님

api/app/worker/emotion.py. PCM 크기·다이내믹·ZCR·F0로 분류한다. 분류용 프롬프트 없음.

텍소노미: sad, angry, whisper, excited, energetic, calm, cheerful. 레거시
neutral/serious→calm, warm→cheerful.

프로젝트 tone_style이 기본. 편집기가 세그먼트 오버라이드를 저장한 경우만 그 값을 쓴다.
분류가 쓰는 비-v3 voice_settings:

tone	stability	similarity_boost	style
sad	0.72	0.78	0.22
angry	0.28	0.70	0.72
whisper	0.88	0.72	0.05
excited	0.22	0.68	0.78
energetic	0.32	0.72	0.65
calm	0.70	0.80	0.10
cheerful	0.40	0.75	0.55

13. 에이전트가 아닌 것

구성	이유
Demucs (htdemucs)	로컬 stem 분리. 프롬프트 없음
ffmpeg / ffprobe	추출, trim, mux, loudness, atempo
rubberband	피치 유지 템포. 경로 힌트만
R2	객체 저장. 모델 아님
yt-dlp	URL 수집 (API). 본 파이프라인 STT/번역 아님
Sync.so lipsync	기본 disabled. 비디오+오디오 URL만. 프롬프트 없음
pyannote	로컬 화자분리 모델
emotion.py	음향 휴리스틱
translation_align.py	길이/스크립트 휴리스틱
vi→ko postprocess	정규식 지명·통화 교정

14. 실패·재시도 정책

오케스트레이터 `_with_retries`: 시도 횟수 = `pipeline_step_retries` + 1 (기본 3).

`PipelineError.retryable`만. 백오프 `pipeline_retry_backoff_seconds * attempt` (2s, 4s, ...). 재시도 사이 취소 검사.

step 이름	호출	retryable
asr, asr_tail	Gemini/Whisper transcribe	HTTP 429/5xx, 네트워크, 빈 JSON, 빈 candidates. 세그먼트 0개는 NO_SEGMENTS(보통 비재시도)
diarization	OpenAI diarize	429/5xx. 실패해도 잡 실패가 아님 — Gemini 화자 fallback
correct_asr	GPT proofread	실패 시 건너뛰고 원문 유지
translate	Gemini/OpenAI translate_batch	429/5xx, JSON shape, 빠진 idx
timing_rewrite	adjust_translation	채팅 실패. 발산 재작성은 재시도가 아니라 폐기
tts	ElevenLabs	클라이언트 내부 + 오케스트레이터. 429/5xx

Gemini HTTP 400 + unknown generation field는 클라이언트 루프(최대 3)에서 필드를 빼고 같은 프롬프트를 다시 보낸다. 검증 오류(소스 너무 김, 컨테이너, CONFIG_MISSING)는 한 번만.

15. 3.0.12 버그 컨텍스트 — 현재 계약

구 동작: Gemini가 클립 전체를 한 문서로 번역(full_translation)한 뒤, 그 문장을 세그먼트 위치나 슬라이스로 idx에 넣었다. 결과는 앞부분·다른 장면이 짧은 줄에 붙거나, 후반 idx가 문서 앞머리를 받는 스크램블이었다. 저장된 segments.target_text가 진실이라 더빙이 틀린 줄을 읽었다.

현행 계약 (이 문서를 따르는 엔지니어는 이것을 유지한다):

1. 워커는 translate_batch(items, document_context=full_source)만 호출한다. translate_document + align_translation_to_segments를 Gemini/워커에 연결하지 않는다.
2. idx N의 출력은 그 행의 source_text만 번역한다. full_transcript는 문맥이다.
3. 서버 매핑은 translations[].idx이다. 빠진 idx는 실패(retryable). 위치 배열로 구멍을 메우지 않는다.
4. 오할당으로 보이는 행은 idxs_needing_retranslate 후, full_transcript 없이 그 idx만 재번역한다.
5. 이미 DB에 있는 틀린 행은 마이그레이션으로 고치지 않는다. 새 transcribe → replace_segments가 필요하다 (DPD-001 11장).

pipeline.py 주석 "Full-document translation (Gemini) then per-idx spoken lines"는 문맥을 넣는다는 뜻이지, 문서 슬라이스 할당이 아니다. 주석을 구계약으로 읽지 말 것.

16. 로케일 부가 규칙 (프롬프트 조각)

locale_rules.translation_pair_rules.vi→ko가 아니면 대부분 빈 문자열.

16.1 Vietnamese → Korean (필수 용어집)

Vietnamese→Korean glossary (mandatory):

- Đà Lạt / Da Lat → 달랏 (highland city). NEVER translate it as 다낭.
- Đà Nẵng / Da Nang → 다낭 (different coastal city).
- Hồ Chí Minh / Sài Gòn → 호치민; Hà Nội → 하노이.

Vietnamese currency spoken form (mandatory for voice-over):

- N triệu = N million đồng. Render in Korean 억/만, not '만' alone and not a raw Latin number.
- Example: 620 triệu → 6억 2천만 (spoken 육억 이천만).
- Example: 1.2 tỷ → 12억; 50 triệu → 5천만.

Keep real-estate terms natural: thổ cư→토지/주거용 토지, mặt tiền→도로 전면, view thung lũng→계곡 전망.

16.2 Vietnamese → 그 외

Preserve Vietnamese place names accurately: Đà Lạt is Da Lat (not Da Nang); Đà Nẵng is Da Nang.
Spell currency for speech: N triệu = N million.

번역 후 apply_vi_ko_postprocess가 다낭↔달랏, N triệu → 억/만을 정규식으로 한 번 더 고친다. 프롬프트가 아니다.

미사용 Whisper 어휘(연결하지 말 것): Đà Lạt, thổ cư, mặt tiền, thung lũng, săn mây, hoàng hôn, triệu, tỷ.

17. 문서 이력

판	날짜	내용
---	----	----

1.0	2026-09-05	코드 3.0.12 / 파이프라인 3.0 기준 최초 AIP. 프롬프트 전문은 저장소에서 전사.
-----	------------	---