

HANDOVER · INTERNAL

시스템 아키텍처 정의서

문서번호 DUBBY-SAD-001

제품 버전 3.0.12

파이프라인 버전 3.0

작성일 2026-09-04

상태 **인수인계용 / 내부**

이 문서는 Dubby의 런타임 배포 네트워크 저장소 인증 경계를 정의한다. 비즈니스 규칙, DB 스키마, 프롬프트 전문은 **최상위 코드 기준 (추측 인프라 없음)**



1. 문서 개요

1.1 목적

이 문서는 Dubby의 시스템 경계를 한 장의 인수인계 기준으로 고정한다. 누가 어디에 배포되고, 요청이 어떤 경로로 흐르며, 파일이 어디를 지나지 않는지, 인증이 무엇을 신뢰하는지를 코드와 배포 설정에 근거해 기술한다.

1.2 범위

- 포함: 프론트엔드·API·워커·리버스 프록시·DNS/도메인·인증·객체 스토리지·외부 SaaS 연동점·운영 헬스체크·환경 변수 이름.
- 제외: 세그먼트 비즈니스 규칙의 세부, 프롬프트 전문, 테이블 DDL과 마이그레이션 이력. 이들은 각각 「비즈니스 로직 및 기능 명세서」, 「AI 에이전트 및 프롬프트 명세서」, 「데이터베이스/파이프라인 설계서」에서 다룬다.
- 사실의 기준: 저장소 현재 코드(제품 버전 3.0.12, PIPELINE_VERSION 3.0). 문서에 없는 클라우드 구성은 가정하지 않는다.

1.3 대상 독자

- 인수받는 개발자·운영자: 배포 단위와 재시작 범위를 파악한다.
- 프론트/백엔드 작업자: CORS·업로드 경로·JWT 경계를 오해하지 않는다.
- 모바일 담당: 웹과 네이티브의 결제·파일 저장 경로가 갈라지는 지점을 본다.

1.4 관련 산출물

문서	역할
본 문서 (SAD-001)	런타임·배포·네트워크·저장 경계
비즈니스 로직 및 기능 명세서 (후속)	제품 기능, 크레딧, 더빙/추출 UX
데이터베이스/파이프라인 설계서 (후속)	스키마, 잡 상태, 미디어 처리 단계
AI 에이전트 및 프롬프트 명세서 (후속)	STT·번역·TTS 프롬프트와 모델
docs/CUSTOM_DOMAIN.md	도메인·DNS·터널 운영 메모
api/.env.example	환경 변수 이름(값 없음)

1.5 용어

용어	의미
UI / Pages	Next.js static export(out /). 서버 런타임 없음.

용어	의미
API	FastAPI(unicorn). 인증·CRUD·프리사인·잡 enqueue.
Worker	파이프라인 실행 프로세스. jobs 테이블을 폴링한다.
Caddy	Lightsail에서 TLS 종료 및 reverse_proxy.
R2	Cloudflare R2. 브라우저가 직접 multipart PUT.
healthz	프로세스 생존. DB/R2를 건드리지 않음. 버전은 API 이미지.
readyz	DB ping. 실패 시 503.

2. 시스템 개요

Dubby는 원본 영상을 올리고, 대본을 추출·수정한 뒤, 대상 언어로 더빙해 내려받는 제품이다. 웹은 정적 사이트이고, 무거운 미디어와 AI 작업은 API가 아닌 워커와 외부 공급자가 수행한다. 브라우저와 앱은 100MB급 원본을 API 본문으로 보내지 않는다.

2.1 한 줄 구조

```
[브라우저 / Capacitor 앱]
| HTTPS (정적 자산)
v
dubbyai.com (GitHub Pages 또는 Cloudflare Pages, out/)
|
| HTTPS + Bearer JWT (JSON만, 본문 작음)
v
api.dubbyai.com --Caddy--> dubby-api:8000 (FastAPI)
|
| jobs enqueue
| v
| dubby-worker (ffmpeg / Demucs / AI)
|
+--> 브라우저 presigned PUT/GET ----> Cloudflare R2
+--> Supabase Auth JWT 검증, Postgres(또는 PostgREST)
+--> Gemini / OpenAI / ElevenLabs / Stripe / RevenueCat
```

2.2 설계 원칙

- 정적 UI: Next.js output: "export". 서버 컴포넌트 런타임·API Route에 의존하지 않는다.
- API는 오케스트레이션만: 파일 바이트를 프록시하지 않고 R2 프리사인을 발급한다.
- 워커는 별 이미지: Demucs/torch는 메모리·이미지 크기가 커서 API와 분리한다.
- 사용자 id는 클라이언트를 믿지 않는다. 모든 소유권은 Supabase JWT sub에서 온다.
- 프로덕션은 PIPELINE_MODE=real 만 허용한다. mock은 개발·테스트 전용이다.

2.3 제품·배포 버전

프론트 package.json과 API api/app/__init__.py의 __version__은 3.0.12로 맞춘다. 파이 프라인 호환 표식 PIPELINE_VERSION은 "3.0"이다. 공개 /healthz의 version 필드는 API 컨테이너에 들어간 그 파일이다. 워커만 재빌드하면 healthz 버전은 바뀌지 않는다.

3. 시스템 컨텍스트

3.1 행위자

행위자	진입점	비고
웹 사용자	https://dubbyai.com	Stripe 결제, 데스크톱 저장 피커
모바일 웹	동일 도메인	저장 피커 생략, 공유/다운로드 경로
네이티브 앱	com.dubby.app	Capacitor, RevenueCat 결제
관리자	/v1/admin	JWT role 기반. 크레딧·로그
결제 공급자	웹훅	Stripe / RevenueCat. 서명·헤더 검증

3.2 외부 시스템

시스템	역할	호출 주체
Supabase Auth	가입·세션 JWT 발급	브라우저 SDK / API 검증
Postgres (Supabase)	프로젝트·세그먼트·잡·크레딧	API·워커 Repository
Cloudflare R2	원본·산출·보이스 샘플	브라우저 PUT, 워커 GET/PUT
Gemini 3.7 Flash	기본 STT·번역	워커
OpenAI	STT·번역 fallback, 화자분리	워커
ElevenLabs	보이스 클론·TTS	워커·API(보이스 라이브러리)
Stripe	웹 구독·크레딧 팩	API
RevenueCat	iOS/Android 인앱결제	앱 + API 웹훅
yt-dlp 대상 사이트	URL 수집	API (ffmpeg + Node 22)
Sync.so	선택 립싱크	워커 (기본 disabled)

3.3 신뢰 경계

- 공개: 정적 UI, /healthz, /readyz, 결제 웹훅(서명 필요).
- 인증 필요: /v1/* (헬스 제외). Authorization: Bearer <Supabase JWT>.
- 브라우저 → R2: 프리사인 URL만. 키 prefix는 서버가 users/{user_id}/... 로 강제한다.
- 워커 → DB: 서비스 측 Repository. 사용자 JWT를 들고 다니지 않는다.
- Caddy는 CORS 헤더를 넣지 않는다. 중복 ACAO는 브라우저가 거절한다.

4. 논리 아키텍처

4.1 계층

Presentation	Next.js 16 static UI (React 19), i18n ko/en/vi Capacitor shell (webDir=out), billingPlatform 분기
Edge / TLS	GitHub Pages 또는 CF Pages (UI) Caddy h1/h2 only (API, Lightsail) 로컬: Cloudflare named tunnel → localhost:8000
Application	FastAPI create_app() CORS → AccessLogMiddleware → routers JwtVerifier, R2Storage, Repository
Pipeline	worker.runner claim_next_job PIPELINE_HANDLERS: transcribe dub lipsync Engine (real mock)
Data	Postgres asyncpg 또는 supabase_rest R2 objects, Demucs model volume

4.2 프론트엔드

next.config.ts는 output: "export", trailingSlash, 비최적화 이미지를 사용한다. NEXT_PUBLIC_SITE_URL 기본값은 https://dubbyai.com 이다. 사이트 URL에 dubbyai.com 이 포함되거나 DUBBY_CUSTOM_DOMAIN=true이면 basePath를 비운다. 커스텀 도메인 없는 GitHub Pages만 /Dubby prefix를 쓴다.

API 오리진은 NEXT_PUBLIC_API_ORIGIN, 쿼리 ?api=, localStorage 순으로 src/lib/api.ts 가 해석한다. 오리진이 비어 있으면 src/lib/demo-api.ts 로컬 데모 백엔드로 떨어진다. 세션은 @supabase/supabase-js PKCE, persist session, anon key이다.

4.3 API

api/app/main.py의 create_app()이 FastAPI를 만든다. 수명주기에서 Repository·R2Storage·JwtVerifier를 app.state에 올린다. 프로덕션에서는 /docs를 끈다. 라우터는 health, projects, segments, jobs, credits, voices, billing, uploads, admin이다.

AccessLogMiddleware는 /v1/* 히트를 DB에 남긴다. CORSMiddleware보다 안쪽에 두어 500 응답에서도 ACAO가 떨어지지 않게 한다. Starlette BaseHTTPMiddleware는 이 이유로 쓰지 않는다.

4.4 워커

python -m app.worker.runner가 jobs를 폴링한다. 기본 동시성 1(WORKER_CONCURRENCY). 핸들러는 transcribe, dub, lipsync. 하트비트 파일로 컨테이너 HEALTHCHECK를 하고, 오래 멈춘 running 잡은 리퍼가 실패 처리한다. 잡 타임아웃 기본 3600초.

4.5 설정 모듈

모든 배포 값은 `api/app/config.py` Settings에만 있다. 코드에 자격 증명을 넣지 않는다.
APP_ENV=production이면 Supabase, DB, R2, Stripe price id, (Gemini STT/번역 사용 시)
GEMINI_API_KEY, PIPELINE_MODE=real을 강제한다.

5. 물리 배포 아키텍처

5.1 프로덕션 목표 형상 (Lightsail)

infra/docker-compose.yml은 단일 Lightsail 인스턴스용이다. 서비스 세 개: api, worker, caddy. 네트워크는 bridge, IPv6 비활성. Docker DNS가 짧은 호스트명 api의 AAAA 조회에서 SERVFAIL을 내면 Caddy(Go)가 깨지므로 API의 네트워크 별칭은 dubby-api이다. Caddyfile은 dubby-api:8000만 본다.

```
Internet
| :80 / :443
v
[caddy:2-alpine] TLS(ACME) protocols h1 h2 (h3 금지)
| reverse_proxy health_uri /healthz
v
[dubby-api:latest] unicorn :8000 workers=1
| DB / R2 / Stripe / JWT
|
[dubby-worker:latest] memory ~6g stop_grace 5m
| volume demucs-models, worker-scratch
v
ffmpeg, rubberband, Noto, CPU torch/Demucs
```

서비스	이미지/타겟	역할
api	Dockerfile target api	unicorn, ffmpeg, Node 22 (yt-dlp JS)
worker	Dockerfile target worker	파이프라인, Demucs CPU, Noto 자막
caddy	caddy:2-alpine	TLS, 본문 10MB, gzip, Alt-Svc 제거

운영 주의 — 이미지 경계

파이프라인·프롬프트 수정은 워커 이미지. healthz version·라우터 수정은 API 이미지. 둘 다 같은 api/ 컨텍스트로 빌드하지만 target이 다르다. compose up --build 시 필요한 타겟을 함께 올린다.

5.2 UI 배포

- 빌드: npm run build → out/.wrangler.jsonc의 pages_build_output_dir은 ./out.
- GitHub Actions .github/workflows/deploy-pages.yml: main 푸시 시 GitHub Pages. GITHUB_PAGES=true, DUBBY_CUSTOM_DOMAIN=true, NEXT_PUBLIC_SITE_URL=https://dubbyai.com, 빈 basePath. out/CNAME = dubbyai.com.
- Cloudflare Pages: wrangler pages deploy out로도 동일 산출물을 올릴 수 있다. 공개 도메인은 dubbyai.com.
- GitHub secrets: NEXT_PUBLIC_SUPABASE_URL, NEXT_PUBLIC_SUPABASE_ANON_KEY, NEXT_PUBLIC_API_ORIGIN. 서비스 롤 키는 UI에 넣지 않는다.

5.3 로컬·터널 형상

개발 PC에서는 API를 :8000 unicorn으로 띄우고, Cloudflare named tunnel로 api.dubbyai.com에 붙일 수 있다. START_SERVICES.md와 scripts/run-named-tunnel.sh가 이 경로다. UI의 NEXT_PUBLIC_API_ORIGIN은 https://api.dubbyai.com을 가리킨다. 터널은 로컬 작업용이며, Lightsail Caddy 스택과 동시에 같은 DNS를 먹으면 충돌한다.

5.4 모바일

capacitor.config.ts: apId com.dubby.app, webDir out. Android scheme https. billingPlatform()은 ios/android면 revenuecat, 그 외 stripe. 네이티브는 웹과 같은 API-R2를 쓰되 결제와 파일 저장만 갈라진다.

5.5 DNS (공개 도메인)

docs/CUSTOM_DOMAIN.md 기준 공개 이름은 dubbyai.com(UI), api.dubbyai.com(API)이다. UI apex는 GitHub Pages(creator1008.github.io) CNAME. API는 Lightsail A레코드+Caddy이거나, 로컬 개발 시 터널 CNAME(주황 구름)이다. 현재 운영 중인 쪽이 어느 DNS인지는 대시보드를 기준으로 하고, 문서에 없는 IP를 적지 않는다.

6. 구성 요소 명세

6.1 정적 UI

항목	값
기술	Next.js 16.2.10, React 19, Tailwind 4
산출	out/ (정적 HTML/JS/CSS)
상태	브라우저. Supabase 세션 + API JSON
i18n	ko / en / vi
대상 언어 목록	src/lib/languages.ts (ko, vi, en, zh, ja 등)
데모 모드	API origin 미설정 시 demo-api.ts

6.2 FastAPI

항목	값
엔트리	uvicorn app.main:app --host 0.0.0.0 --port 8000 --workers 1
헬스	컨테이너 HEALTHCHECK → /healthz
첨부 바이너리	ffmpeg, Node 22 (yt-dlp 챌린지)
업로드 한도(프록시)	Caddy request_body max_size 10MB — JSON·웹hook
원본 한도(제품)	최대 30분, 500MB (워커/검증). R2 경유

6.3 Worker

항목	값
엔트리	python -m app.worker.runner
동시성	기본 1 (Demucs 메모리)
메모리 리밋	WORKER_MEMORY_LIMIT 기본 6g
종료	stop_grace_period 5m (진행 중 잡 drain)
모델 캐시	volume demucs-models → TORCH_HOME
헬스	WORKER_HEARTBEAT_FILE 60초 이내 mtime

6.4 Caddy

- {\$DUBBY_API_DOMAIN} 사이트 블록. ACME 메일 {\$ACME_EMAIL}.

- `servers.protocols`: h1 h2. HTTP/3 비활성. header `-Alt-Svc`.
- 이유: Chrome이 Alt-Svc h3를 오래 캐시하고, Lightsail QUIC/UDP 실패가 `net::ERR_FAILED` + CORS처럼 보인다.
- `reverse_proxy` `dubby-api:8000`, `health_uri /healthz`, 30초.
- `Access-Control-*` 를 Caddy에 두지 말 것.

6.5 로컬 전용 프로세스

`api/app/local_step12.py`는 포트 8002의 로컬 step1/2 실험용이다. `npm run dev:step12`. 프로덕션 이미지 CMD에 포함되지 않는다. 인수 시 이 프로세스를 Lightsail에 올리지 않는다.

7. API 표면

인증이 없는 엔드포인트는 헬스뿐이다. 나머지는 Bearer JWT. 웹훅은 별도 서명.

영역	경로 접두	책임
health	/healthz, /readyz	생존 / DB 준비
projects	/v1/projects	CRUD, URL 수집, 다운로드 URL
segments	/v1/projects/.../segments	자막 조회·수정·재번역
jobs	/v1/projects/{id}/jobs	transcribe / dub / lipsync enqueue
uploads	/v1/uploads/multipart	R2 create / sign / complete / abort
credits	/v1/credits	잔액·원장 조회
voices	/v1/voices	라이브러리·마이보이스·IVC
billing	/v1/billing	Stripe Checkout, 웹훅
admin	/v1/admin	사용자·크레딧 조정·엑세스 로그

7.1 업로드 프로토콜

- POST /v1/uploads/multipart → upload_id, key, 파트 크기(최대 16MiB).
- POST .../parts → 파트별 프리사인. 브라우저가 R2에 PUT, ETag 수집.
- POST complete 또는 abort. API는 바이트를 받지 않는다.
- 키는 항상 서버가 users/{user_id}/...로 만들고, 이후 요청마다 prefix를 재검증한다.

7.2 잡

API는 잡 행만 넣는다. 실행은 워커. dub/lipsync는 프로젝트 duration 기준으로 크레딧을 선과 금한다. 동일 프로젝트에 활성 잡이 있으면 ActiveJobExistsError → 409.

8. 데이터와 스토리지

8.1 Repository

api/app/db/의 Repository 인터페이스만 사용한다. postgres(asyncpg, Lightsail 권장, 풀 1-5) 또는 supabase_rest(PostgREST + service role). 스키마 상세는 후속 DB 설계서. 이 문서는 접근 경로만 고정한다.

8.2 R2 키 레이아웃

```
users/{user_id}/projects/{project_id}/source/{filename}
users/{user_id}/projects/{project_id}/outputs/...
users/{user_id}/projects/{project_id}/meta/...
users/{user_id}/voices/inbox/{uuid}/{filename}
```

엔드포인트: `https://{R2_ACCOUNT_ID}.r2.cloudflarestorage.com`

서명: S3v4 path-style. 빈 바디 CRC 체크섬을 프리사인에 붙이지 않음

(브라우저 PUT 실패와 불일치하면 R2가 파트를 거절)

파트: 최소 5MiB(마지막 제외), 상한 16MiB. 구 env의 64MiB는 config가 잘라 낸다.

프리사인 만료: 업로드 3600s, 다운로드 60-3600s.

8.3 워커 로컬 디스크

잡마다 scratch 디렉터리. 컨테이너는 worker-scratch 볼륨을 /tmp에 붙인다. Demucs 가중치는 demucs-models 볼륨에 남겨 재생성 비용을 줄인다. 완료·실패 후 scratch는 정리한다.

9. 인증과 권한

9.1 JWT

api/app/auth.py JwtVerifier. 헤더 Authorization: Bearer. SUPABASE_JWT_SECRET가 있고 알고리즘이 HS256이면 대칭키 검증. 아니면 프로젝트 JWKS(ES256/RS256). audience 기본값 authenticated. AuthenticatedUser.id는 토큰 sub뿐이며, 바디의 user id는 소유권 근거가 아니다.

9.2 관리자

AdminUser 의존성. JWT role 등으로 /v1/admin을 연다. 일반 사용자 크레딧 원장은 서버만 기록한다.

9.3 웹훅

- Stripe: stripe_webhook_secret 서명 검증.
- RevenueCat: revenuecat_webhook_auth_header와 Authorization 일치.
- 웹훅은 브라우저 CORS 경로가 아니다. Caddy 10MB면 충분하다.

9.4 프론트 키

UI는 anon key와 Supabase URL만 가진다. service role, R2 시크릿, Stripe secret, Gemini 키는 Lightsail env(또는 로컬 api/.env)에만 둔다. 저장소에 .env를 커밋하지 않는다.

10. 네트워크와 보안

10.1 CORS

credentialed CORS. 와일드카드 Origin/* 헤더는 쓰지 않는다. `config.cors_origin_list`는 설정값에 더해 `dubbyai.com`, `www`, `dubby.pages.dev`, GitHub Pages, `localhost:3000`, `https://localhost`, `capacitor://localhost`를 항상 포함한다. 정규식은 `*.pages.dev`와 `localhost` 포트를 추가로 받는다. 허용 메서드 GET/POST/PUT/PATCH/DELETE/OPTIONS. 헤더 Authorization, Content-Type, Accept, Origin, X-Requested-With, Bypass-Tunnel-Reminder. `max_age` 86400.

10.2 본문 크기와 업로드

Caddy 10MB ≠ 원본 업로드 한도

프로젝트 소스와 보이스 클론 미디어는 프리사인 R2로 간다. Caddy 한도를 100MB로 올리는 것은 설계가 아니다. JSON·웹훅만 프록시를 지난다.

10.3 HTTP/3

API 사이트는 h3를 켜지 않는다. 이미 Alt-Svc를 받은 Chrome은 오래 QUIC을 시도할 수 있으므로 Caddy가 Alt-Svc를 지운다. UI(정적 호스트)의 HTTP/3는 이 제약과 별개다.

10.4 컨테이너 네트워크

- `enable_ipv6`: `false`. Caddy에 `GODEBUG=netdns=go`.
- API 호스트 별칭 `dubby-api`. 짧은 이름 `api`로 프록시하지 말 것.
- API 포트 8000은 `expose`만. 공인은 443. 디버그 시에만 8000 매핑.

11. 주요 요청 흐름

11.1 로그인

```
UI --PKCE--> Supabase Auth --> 세션 JWT (local persist)
UI --Authorization: Bearer--> API JwtVerifier
실패: 401. 클라이언트 user_id 헤더는 없음.
```

11.2 원본 업로드 후 프로젝트

1. UI POST /v1/uploads/multipart (메타만)
2. UI PUT part → R2 (16MiB 단위, 반복)
3. UI POST /v1/uploads/multipart/complete
4. UI POST /v1/projects (source_key 등 JSON)
5. (선택) POST .../source-from-url → API yt-dlp+ffmpeg → R2

11.3 추출 (transcribe)

```
UI POST /v1/projects/{id}/jobs { kind: transcribe }
API: jobs 행 queued
Worker: claim → R2 GET source → ffmpeg
       → STT(Gemini 기본) → 세그먼트 persist → progress report
UI: 잡 폴링, 세그먼트 에디터
```

11.4 더빙 (dub)

```
UI POST jobs { kind: dub }
API: duration 기반 크레딧 선과금, queued
Worker: 번역(필요 시) → ElevenLabs TTS → Demucs 음성 제거
       → mix_no_vocals_in_mask(기본 0.8) 믹스 → mux → R2 outputs
UI: 프리사인 GET으로 재생/저장 (API가 파일을 스트리밍하지 않음)
```

11.5 결제

웹: Stripe Checkout. 성공 웹훅이 크레딧 원장에 분. 네이티브: RevenueCat → 웹훅 Authorization 일치 시 분 부여. 가입 시 signup_credit_minutes 기본 30.

12. 설정 (이름만, 값 없음)

값은 이 문서에 적지 않는다. 이름과 용도만 고정한다. 실값은 `infra/.env` 또는 `api/.env`.

12.1 프로덕션 필수

변수	용도
APP_ENV=production	부트 시 필수값 검증, /docs 비활성
PIPELINE_MODE=real	production에서 mock 거부
SUPABASE_URL	JWKS-Auth
DATABASE_URL	db_backend=postgres 일 때
R2_ACCOUNT_ID / ACCESS / SECRET	프리스این
STRIPE_SECRET_KEY, WEBHOOK, PRICE_ID 둘	웹 결제
GEMINI_API_KEY	STT/번역 provider=gemini 일 때
DUBBY_API_DOMAIN, ACME_EMAIL	Caddy TLS

12.2 UI 빌드 타임

변수	용도
NEXT_PUBLIC_SITE_URL	OAuth 리다이렉트. localhost 폴백 금지
NEXT_PUBLIC_API_ORIGIN	브라우저가 호출할 API
NEXT_PUBLIC_SUPABASE_URL / ANON_KEY	클라이언트 Auth
DUBBY_CUSTOM_DOMAIN / GITHUB_PAGES	basePath 결정

12.3 자주 조정하는 런타임

- WORKER_CONCURRENCY, WORKER_MEMORY_LIMIT
- DEMUCS_MODEL (기본 htdemucs), DEMUCS_DEVICE (기본 cpu)
- MIX_NO_VOCALS_IN_MASK (기본 0.8)
- STT_PROVIDER / TRANSLATION_PROVIDER (기본 gemini)
- ELEVENLABS_TTS_MODEL (기본 eleven_v3)
- LIPSYNC_PROVIDER (기본 disabled)
- CORS_ORIGINS (추가 Origin. 필수 목록은 코드가 합친다)

13. 운영과 관측

13.1 헬스

엔드포인트	의미	실패 시
/healthz	프로세스 up + env + version	컨테이너/Caddy unhealthy
/readyz	repository.ping()	503 degraded
워커 HEALTHCHECK	heartbeat 파일 60s	compose restart

13.2 로그

json-file, 파일당 10m, 3개. AccessLogMiddleware가 인증된 /v1 히트를 DB에 남긴다. 워커는 잡 단위 logger. 파이프라인 단계 메시지는 jobs.progress로 UI 라벨과 연결된다.

13.3 배포 체크리스트

- UI만 바꾸면 Pages 빌드(푸시 main 또는 wrangler). API 재시작 불필요.
- 라우터·버전·CORS면 API 이미지 재빌드. healthz.version으로 확인.
- STT/번역/믹스/ffmpeg면 워커 이미지 재빌드. 진행 중 잡은 5분 grace.
- 기존 프로젝트의 잘못된 세그먼트는 코드만으로 고쳐지지 않는다. 추출을 다시 돌려야 한다(더빙만 재실행하면 옛 자막을 유지).

13.4 용량 가드레일

원본 최대 30분·500MB. 업로드 안전 상한 4GiB(스토리지). 워커 잡 타임아웃 1시간. 스텝 재시도 기본 2회, 백오프 2초. 하트비트 20초.

14. 제약과 운영 주의

- API workers=1. 수평 확장은 이 compose에 없다. 워커 동시성도 기본 1.
- Lightsail에 GPU 전제가 없다. Demucs는 CPU 실행.
- 프로덕션 OpenAPI(/docs) 비활성.
- multipart 파트 16MiB 캡. 브라우저 두 번째 PUT 안정성.
- Windows 호스트 경로가 .env에 있어도 리눅스 컨테이너는 ffmpeg PATH로 정규화한다.
- IPv6 Docker DNS와 짧은 호스트명 api 조합을 다시 넣지 말 것.
- Caddy에 CORS를 중복 설정하지 말 것.
- 로컬 step12(:8002)를 공인 엔드포인트로 쓰지 말 것.
- 시크릿.env·터널 로그.wrangler/tmp 는 저장소에 올리지 않는다.

14.1 명시적으로 다루지 않는 것

멀티 리전, GPU 워커 풀, CDN 앞단의 API 캐시, D1/KV 세션. 현재 코드 경로에 없으면 이 아키텍처의 구성 요소가 아니다.

15. 부록 — 저장소 맵

경로	내용
src/	Next.js UI
src/lib/api.ts, supabase.ts, mobile.ts	오리진·세션·네이티브 분기
next.config.ts, wrangler.jsonc	static export, Pages 산출
capacitor.config.ts	네이티브 셸
.github/workflows/deploy-pages.yml	GitHub Pages CI
api/app/main.py	FastAPI 팩토리
api/app/config.py	환경 변수
api/app/auth.py	JWT
api/app/routers/	HTTP 표면
api/app/db/	Repository
api/app/storage/r2.py	프리사인
api/app/worker/	러너·파이프라인·엔진
api/Dockerfile	api / worker 멀티 타깃
infra/docker-compose.yml, Caddyfile	Lightsail 스택
api/app/local_step12.py	로컬 전용. 비프로덕션

15.1 개정

버전	일자	내용
1.0	2026-09-04	코드 3.0.12 기준 최초 아키텍처 정의서

다음 인수 문서: 「비즈니스 로직 및 기능 명세서」. 본 문서는 그 기능이 어느 프로세스에서 실행되는지만 정의한다.